Aplicação do CRISP-DM ao MVC Finance

Item	Identificação
Instituição	Centro Universitário do Distrito Federal – UDF
Disciplina	Ciência de Dados e Aprendizagem de Máquina – A1
Docente	Profa. Kadidja Valéria
Integrantes	Isabella Ana Dutra de Sousa (35719117); Kauane Braga dos Santos Silva de Sousa (36358959)
Projeto-base	TCC "MVC Finance: aplicativo web de gestão financeira pessoal" (UDF, 2026)

Introdução

Este trabalho aplica as seis fases do CRISP-DM ao MVC Finance para planejar um projeto de mineração de dados que recomende cursos e antecipe o risco de saldo negativo a partir das transações do próprio usuário.

O MVC Finance é uma aplicação SaaS que une controle financeiro (depósitos, despesas e investimentos) a um módulo educacional com seis cursos, XP e conquistas. A conclusão do TCC reconhece uma lacuna: a integração entre os dois módulos ainda é apenas de navegação, pois os cursos não são recomendados com base nos dados financeiros do usuário. Esse ponto, listado como trabalho futuro, é o problema de negócio escolhido aqui.

O CRISP-DM (Cross-Industry Standard Process for Data Mining) foi adotado por ser um processo padronizado, aplicável a qualquer setor e iterativo: as fases podem retornar umas às outras conforme surgem novas descobertas. Cada fase abaixo segue a estrutura do guia da disciplina: objetivo central, checklist de execução e aplicação prática ao MVC Finance.

Sigla	Significado	No MVC Finance
CR (Cross-Industry)	Padrão aplicável a vários segmentos de mercado	Aplicado a uma fintech de educação financeira
SP (Standard Process)	Processo padronizado e estruturado	As seis fases guiam o trabalho das duas perguntas
DM (Data Mining)	Focado em mineração de dados e análises preditivas	Clusterização (P1) e previsão de saldo negativo (P2)

Como **metodologia**, o CRISP-DM define as fases típicas, as tarefas de cada uma e a relação entre a equipe de negócio e a equipe técnica. Como **modelo de processo**, dá uma visão do ciclo de vida completo e transforma um problema abstrato ("integrar finanças e educação") em um roteiro acionável. Três características orientam a aplicação neste trabalho:

- **Não linearidade:** as fases retornam umas às outras. Aqui, a avaliação levou de volta à preparação dos dados duas vezes.
- **Centralidade dos dados:** o banco PostgreSQL do MVC Finance é o eixo que liga o entendimento e a preparação.
- **Flexibilidade:** o processo foi adaptado ao projeto, com sprints de duas semanas (Scrum), como no TCC.

Como o sistema ainda não possui base de usuários reais, este documento é um **plano de projeto**: as metas numéricas são propostas pela equipe e deverão ser validadas quando houver dados de produção.

Perguntas de análise

O trabalho responde a duas perguntas, uma sob responsabilidade de cada integrante. As duas percorrem as seis fases do CRISP-DM sobre a mesma base de dados.

Pergunta	Responsável	Técnica	Critério técnico
P1. Quais perfis de consumo existem entre os usuários do MVC Finance e qual curso recomendar a cada um?	Isabella Ana Dutra de Sousa	Clusterização (K-means) e regras "perfil → curso"	Silhueta > 0,25 e cada cluster com ≥ 5% dos usuários
P2. É possível prever, no início do mês, se o usuário terminará o mês seguinte com saldo negativo?	Kauane Braga dos Santos Silva de Sousa	Classificação (regressão logística, árvore de decisão e Random Forest)	Recall ≥ 0,70 e F1 acima do modelo base

Fase 1 – Entendimento do Negócio

O objetivo de negócio é transformar a integração entre finanças e educação, hoje apenas de navegação, em uma integração orientada pelos dados de cada usuário, contribuindo para a prevenção do endividamento.

Objetivo central da fase: traduzir o problema do MVC Finance em metas técnicas viáveis antes de investir esforço computacional.

1.1 Objetivos de negócio e critérios de sucesso

O TCC parte do alto endividamento das famílias brasileiras (CNC, 2024) e da constatação de que o conhecimento, sozinho, não muda o comportamento financeiro (CVM, 2017). Hoje o usuário escolhe cursos livremente, sem relação com seus gastos, e o sistema só mostra o saldo negativo depois que ele já ocorreu.

Pergunta	Objetivo de negócio	Critério de sucesso proposto
P1 (Isabella)	Recomendar o curso mais adequado ao perfil de gastos de cada usuário	Pelo menos 25% dos usuários que recebem uma recomendação iniciam o curso indicado em até 30 dias

Pergunta	Objetivo de negócio	Critério de sucesso proposto
P2 (Kauane)	Alertar o usuário, no início do mês, quando houver risco de terminar com saldo negativo	Queda de 10% na proporção de meses com saldo negativo entre usuários ativos após 3 meses de uso do alerta

Como consequência das duas respostas, o relatório de IA do Plano Premium também poderá receber o perfil e os totais por categoria, como previsto nos trabalhos futuros do TCC.

1.2 Avaliação da situação

- **Recursos:** banco PostgreSQL no Neon acessado via Prisma ORM; equipe de três integrantes já organizada em sprints de duas semanas (Scrum) no ClickUp; análise feita em Python (pandas e scikit-learn), sem custo de licença.
- **Riscos:** base inicial pequena (*cold start*); o Plano Gratuito limita o registro a 10 operações por mês (RN-P01), o que trunca o histórico desses usuários; o registro é manual, então há gastos não lançados; dados financeiros são pessoais e exigem cuidados da LGPD (Brasil, 2018).
- **Custo-benefício:** os modelos rodam em lote, uma vez por mês, fora da aplicação web, com custo de processamento baixo. O benefício é responder diretamente à limitação apontada na conclusão do TCC.

1.3 Metas técnicas de mineração de dados

1. **P1 – Segmentação (clusterização), Isabella:** agrupar usuários em perfis de consumo a partir da proporção de gastos em cada uma das 15 categorias de despesa e da taxa de investimento. Depois, associar cada perfil a um dos seis cursos dos três níveis (Fundamentos, Construção de Patrimônio e Liberdade Financeira).
2. **P2 – Classificação, Kauane:** prever se o próximo mês do usuário terminará com saldo negativo, calculado pela regra RN-D02 (depósitos – investimentos – despesas).

1.4 Plano de projeto

O plano reserva para a Preparação dos Dados a maior fatia do tempo, seguindo a referência de 50% a 70% do esforço total indicada no guia.

Fase	Sprints (2 semanas)	Entrega
1. Entendimento do negócio	0,5	Objetivos, critérios e metas técnicas aprovados
2. Entendimento dos dados	1	Relatório de qualidade dos dados
3. Preparação dos dados	4 (50% do total)	Tabela analítica usuário-mês
4. Modelagem	1	Modelos treinados e métricas técnicas
5. Avaliação	0,5	Decisão: implementar ou iterar

Fase	Sprints (2 semanas)	Entrega
6. Implementação	1	Recomendação e alerta em produção, com monitoramento
Total	**8**	

Fase 2 – Entendimento dos Dados

Os dados necessários já existem no banco do MVC Finance, mas o modelo de dados revela problemas de qualidade que precisam ser tratados antes da modelagem.

Objetivo central da fase: acessar, quantificar e qualificar a matéria-prima disponível para evitar falhas imprevistas na modelagem.

2.1 Coleta dos dados iniciais

Todos os dados são internos (existentes); não há dados comprados. O único dado externo é o plano do usuário, guardado nos metadados do Clerk.

Fonte (entidade)	Atributos de interesse	Uso no projeto
Operacao	valor, data, idTipoOperacao, idCategoria, idMetodoPagamento, usuarioId	Base de todos os indicadores financeiros
TipoOperacao	Depósito, Despesa, Investimento	Cálculo do saldo (RN-D02)
Categoria	28 categorias: 15 de despesa, 7 de depósito, 6 de investimento	Perfil de consumo
MetodoPagamento	6 métodos (crédito, débito, Pix, boleto, dinheiro etc.)	Peso do cartão de crédito nos gastos
Usuario	totalXp, idCursoAtual, idModuloAtual	Engajamento educacional
ProgressoUsuarioLicao / ProgressoUsuarioQuestionario	licaoRealizada, qtdAcertos, datas	Cursos já feitos (não recomendar de novo)
Auditoria	eventos de login e conclusão, com data e hora	Frequência de uso
Clerk (externo)	publicMetadata.subscriptionPlan	Separar Plano Gratuito e Premium

2.2 Descrição de quantidade e qualidade

- **Volume:** usuários do Plano Gratuito geram no máximo 10 operações por mês; os do Premium não têm limite. O volume por usuário será, portanto, muito desigual.
- **Tipos de valores:** valor em Decimal(10,2), sempre positivo (RN-O02 e RN-O03); data em Datetime; tipo, categoria e método como chaves estrangeiras (códigos inteiros).
- **Códigos:** o usuário é identificado pelo e-mail, que é a chave primária de Usuario. Esse dado pessoal precisa ser substituído por um código antes da análise.

2.3 Exploração dos dados e hipóteses iniciais

A exploração usará histogramas de valores por categoria, gráficos de saldo mensal por usuário e matrizes de correlação entre categorias. As hipóteses a testar são:

- **H1:** usuários com maior proporção de gastos em lazer e no cartão de crédito têm mais meses com saldo negativo.
- **H2:** usuários do Plano Gratuito registram menos despesas do que realmente têm, por causa do limite de 10 operações.
- **H3:** usuários que concluem o curso de Fundamentos aumentam a proporção de investimentos nos meses seguintes.

2.4 Verificação da qualidade

Problema esperado	Origem no sistema	Exemplo
Erros de digitação no valor	Registro manual	Lanche de R$ 3.500,00 no lugar de R$ 35,00
Categoria incoerente com o tipo	O sistema não restringe combinações (RN-O08)	Despesa registrada em uma categoria de depósito
Dados omissos	Gastos não lançados; mês sem registro não significa mês sem gasto	Usuário que só registra despesas grandes
Histórico truncado	Limite do Plano Gratuito (RN-O04)	10ª operação do mês bloqueada
Histórico apagado	Exclusão permanente, sem lixeira (RN-O07)	Operações excluídas somem da base
Inconsistência de medição	Data da operação livre	Operações com data futura
Falta de histórico da IA	O relatório de IA não é armazenado (RN-IA05)	Não é possível saber o que já foi sugerido

Fase 3 – Preparação dos Dados

A preparação transforma as operações brutas em uma tabela analítica com uma linha por usuário e por mês, pronta para os algoritmos; é a fase que consome mais tempo do projeto (4 de 8 sprints, ou 50%).

Objetivo central da fase: transformar, limpar e empacotar os dados brutos em um formato digerível pelos algoritmos.

3.1 Selecionar (filtrar)

- Manter apenas usuários com pelo menos 3 meses com operações registradas, para que haja histórico suficiente.
- Retirar atributos pessoais e desnecessários: nomeUsuario, imgUsuario e tituloOperacao (texto livre que pode conter dados pessoais).
- Substituir o e-mail (chave de Usuario) por um código pseudônimo gerado por função de hash, em linha com a LGPD.
- Excluir as contas dos três administradores, que são contas de teste da equipe.

3.2 Limpar (tratar)

- **Valores atípicos:** identificar, por categoria, valores fora do intervalo interquartil (IQR) ampliado; os casos extremos são marcados e revisados, não apagados automaticamente.
- **Categoria incoerente com o tipo:** reclassificar quando o tipo for evidente (ex.: despesa em categoria de depósito) ou descartar a operação.
- **Datas futuras:** descartar operações com data posterior à data da extração.
- **Meses sem registro:** tratar como dado ausente, e não como gasto zero, para não criar falsos "meses econômicos".
- **Plano Gratuito:** marcar os meses em que o limite de 10 operações foi atingido, pois esses meses provavelmente estão incompletos.

3.3 Construir (derivar atributos)

Atributo derivado	Cálculo	Fase que usa
total_depositos, total_despesas, total_investimentos	Soma de valor por tipo no mês	Classificação
saldo_mes	depósitos – investimentos – despesas (RN-D02)	Classificação
taxa_investimento	investimentos ÷ depósitos	Clusterização
perc_categoria (15 colunas)	despesa da categoria ÷ total de despesas	Clusterização
perc_credito	despesas no cartão de crédito ÷ total de despesas	Ambas
qtd_operacoes, dias_com_registro	Contagens no mês	Qualidade e engajamento
variacao_despesas	Variação percentual das despesas	Classificação

Atributo derivado	Cálculo	Fase que usa
	sobre o mês anterior	
licoes_no_mes, totalXp, curso_atual	Progresso educacional	Recomendação
alvo: saldo_negativo_proximo_mes	1 se o saldo_mes do mês seguinte for menor que zero; 0 caso contrário	Classificação

3.4 Integrar (mesclar)

As tabelas são mescladas pelo código do usuário: Operacao com TipoOperacao, Categoria e MetodoPagamento; o resultado agregado por mês é unido ao progresso educacional e ao plano vindo do Clerk. A extração é feita em uma cópia somente leitura do banco, sem afetar a aplicação. Exemplo da agregação mensal em SQL:

```
SELECT o."usuarioId",
       date_trunc('month', o.data) AS mes,
       SUM(CASE WHEN t."tipoOperacao" = 'Depósito'     THEN o.valor ELSE 0
END) AS total_depositos,
       SUM(CASE WHEN t."tipoOperacao" = 'Despesa'      THEN o.valor ELSE 0
END) AS total_despesas,
       SUM(CASE WHEN t."tipoOperacao" = 'Investimento' THEN o.valor ELSE 0
END) AS total_investimentos,
       COUNT(*) AS qtd_operacoes
FROM "Operacao" o
JOIN "TipoOperacao" t ON t."idTipoOperacao" = o."idTipoOperacao"
WHERE o.data <= now()
GROUP BY o."usuarioId", date_trunc('month', o.data);
```

Fase 4 – Modelagem

A modelagem combina uma técnica de clusterização (K-means) para descobrir perfis de consumo e uma de predição (classificadores supervisionados) para estimar o risco de saldo negativo, sempre começando por modelos simples.

Objetivo central da fase: aplicar técnicas matemáticas, gerar designs de teste e iterar parâmetros para descobrir padrões de alto valor.

4.1 Seleção das técnicas

Meta técnica	Técnica	Justificativa
Perfis de consumo	K-means, com atributos padronizados (StandardScaler)	Simples, rápido e com grupos fáceis de explicar pelo centro de cada cluster
Risco de saldo negativo (modelo	Regressão logística	Referência mínima de desempenho e

Meta técnica	Técnica	Justificativa
base)		coeficientes interpretáveis
Risco de saldo negativo (modelo candidato)	Árvore de decisão e Random Forest	Capturam relações não lineares; a árvore gera regras que podem ser explicadas ao usuário
Recomendação de curso	Regras "perfil → curso", definidas com base nos centros dos clusters	Liga a análise aos seis cursos já existentes, sem precisar de histórico de cliques

Exemplos de perfis que podem surgir (a confirmar com os dados): "consumo essencial", com gastos concentrados em moradia, alimentação, saúde e transporte; "lazer e crédito elevados"; e "poupador/investidor", com alta taxa de investimento. O primeiro e o segundo seriam direcionados aos cursos do nível Fundamentos; o terceiro, aos níveis Construção de Patrimônio e Liberdade Financeira.

4.2 Design de teste (partição treino/teste)

- **Partição temporal:** treinar com os meses mais antigos e testar com os 3 meses mais recentes. Uma divisão aleatória deixaria o modelo "ver o futuro" (vazamento de dados).
- **Separação por usuário:** validar também com usuários que não aparecem no treino, para medir a capacidade de generalização.
- **Desbalanceamento:** meses com saldo negativo tendem a ser minoria, por isso usa-se validação cruzada estratificada e peso maior para a classe positiva (class_weight).
- **Escolha de k no K-means:** testar k de 3 a 6 e escolher pelo método do cotovelo e pelo coeficiente de silhueta.

4.3 Construção, iteração e avaliação técnica

Seguindo o princípio de executar modelos básicos cedo, a primeira iteração usa a regressão logística e o K-means com poucos atributos; as seguintes ajustam hiperparâmetros (profundidade da árvore, número de árvores, valor de k) e incluem novos atributos.

Modelo	Métrica técnica	Meta proposta
K-means	Coeficiente de silhueta	Acima de 0,25 e clusters com pelo menos 5% dos usuários cada
Classificadores	Recall da classe "saldo negativo"	Pelo menos 0,70
Classificadores	F1-score e AUC-ROC	Superar a regressão logística (modelo base)

O recall foi priorizado porque deixar de alertar um usuário que ficará negativo custa mais do que um alerta desnecessário.

Fase 5 – Avaliação

Os modelos só seguem para produção se atenderem aos critérios de negócio da Fase 1; uma boa silhueta ou um bom recall, sozinhos, não bastam (impacto real > precisão técnica).

Objetivo central da fase: medir a eficácia dos modelos finais exclusivamente pela lente dos critérios de sucesso definidos na Fase 1.

5.1 Os resultados respondem à meta?

- **Recomendação:** um teste A/B por 30 dias compara um grupo que recebe o curso recomendado com um grupo que vê o catálogo sem recomendação. A meta é que pelo menos 25% do primeiro grupo inicie o curso indicado.
- **Alerta de risco:** acompanha-se a proporção de meses com saldo negativo dos usuários alertados por 3 meses, buscando a queda de 10% definida na Fase 1.
- **Sentido comercial:** os perfis precisam ser compreensíveis. Como o TCC aponta que os cursos não foram validados por especialistas, o mapeamento "perfil → curso" deve ser revisado por um profissional de finanças antes da liberação.

5.2 Revisão de falhas no processo

- Verificar se algum atributo usa informação do próprio mês que se quer prever (vazamento de dados).
- Verificar viés de plano: usuários Premium registram mais operações e podem dominar o treino, prejudicando a qualidade para o Plano Gratuito.
- Conferir se os meses marcados como incompletos na Fase 3 não distorceram os perfis.

5.3 Decisão: implementar ou iterar?

Situação encontrada	Decisão
Critérios técnicos e de negócio atingidos	Implementar (Fase 6)
Boa métrica técnica, mas perfis sem sentido para o negócio	Voltar à Fase 1 e rever a premissa de negócio
Desempenho ruim para usuários do Plano Gratuito	Voltar às Fases 2 e 3: criar modelo separado ou enriquecer a base

Nova pergunta prevista: as recomendações tendem a ser piores para quem usa o Plano Gratuito, pois o limite de 10 operações por mês gera um retrato incompleto dos gastos. Uma resposta possível é usar também os dados educacionais (cursos concluídos e acertos nos questionários) para enriquecer o perfil desses usuários.

Fase 6 – Implementação

Os modelos aprovados entram no MVC Finance como um processamento mensal em lote, cujos resultados aparecem no painel de ensino (curso recomendado) e no dashboard financeiro (alerta de risco).

Objetivo central da fase: incorporar formalmente os modelos ao sistema ou usar as descobertas para mudar a estratégia.

6.1 Plano de implementação (arquitetura)

1. Um job em Python, agendado para o primeiro dia de cada mês, lê a cópia somente leitura do banco no Neon, recalcula os atributos e aplica os modelos.
2. Os resultados são gravados em duas novas entidades, criadas por migração do Prisma: **PerfilUsuario** (usuário, cluster, curso recomendado, data do cálculo) e **AlertaRisco** (usuário, mês, probabilidade de saldo negativo).
3. O Next.js lê essas entidades no servidor, respeitando o isolamento por usuário (RN-U06), e exibe o card "Curso recomendado para você" e o aviso de risco no dashboard.
4. O relatório de IA do Plano Premium passa a receber o perfil e os totais por categoria, em vez da lista bruta de operações, o que também reduz os dados enviados à OpenAI.

6.2 Plano de monitoramento (obsolescência do modelo)

- Comparar, todo mês, a distribuição dos gastos por categoria com a do período de treino (*data drift*).
- Medir o recall real do alerta: dos usuários que terminaram o mês negativos, quantos foram alertados.
- Acompanhar a taxa de início dos cursos recomendados.
- Retreinar os modelos a cada trimestre ou quando alguma métrica cair abaixo da meta.

6.3 Papéis da equipe

Papel	Responsabilidade
Desenvolvimento web	Criar o card de recomendação e o aviso de risco nas telas existentes
Banco de dados	Criar as entidades PerfilUsuario e AlertaRisco e a cópia somente leitura
Ciência de dados	Manter o job mensal, o monitoramento e o retreino
Product Owner	Priorizar os ajustes no backlog do ClickUp a partir do feedback

6.4 Privacidade e transparência

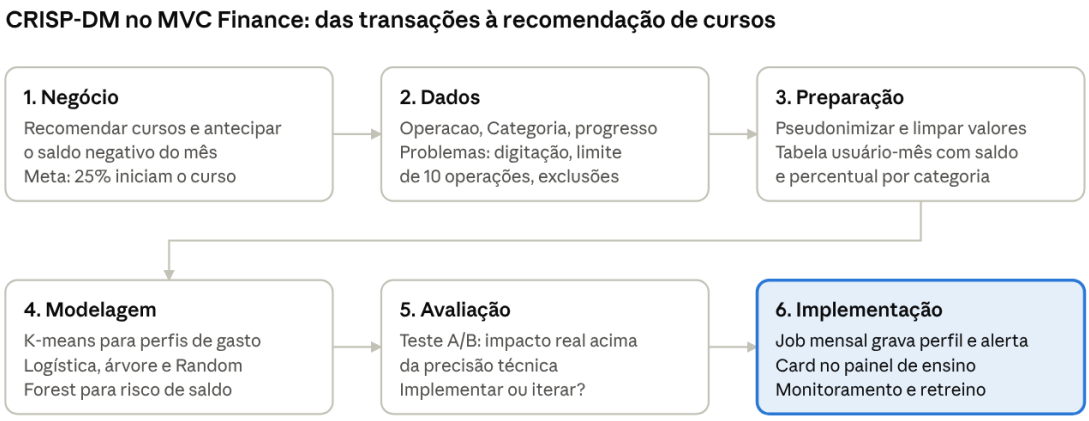
O usuário será informado de que seus dados financeiros são usados para gerar recomendações e poderá desativar o recurso, seguindo o mesmo princípio de transparência previsto para o relatório de IA (RN-IA07). A análise usa dados pseudonimizados e não envia dados pessoais a terceiros.

6.5 Relatório final, feedback e revisão do projeto

Ao final, a equipe entrega o relatório e a apresentação com os resultados do teste A/B e registra as lições aprendidas. Um feedback esperado, como no caso do guia, é a resistência de parte dos usuários a alertas automáticos; por isso o aviso deve ter tom educativo e direcionar para uma lição, e não apenas apontar o problema.

Síntese prática e iterações previstas

Em uma frase: partimos da lacuna apontada no TCC, transformamos as transações em perfis e previsões e devolvemos ao usuário um curso recomendado e um alerta preventivo.



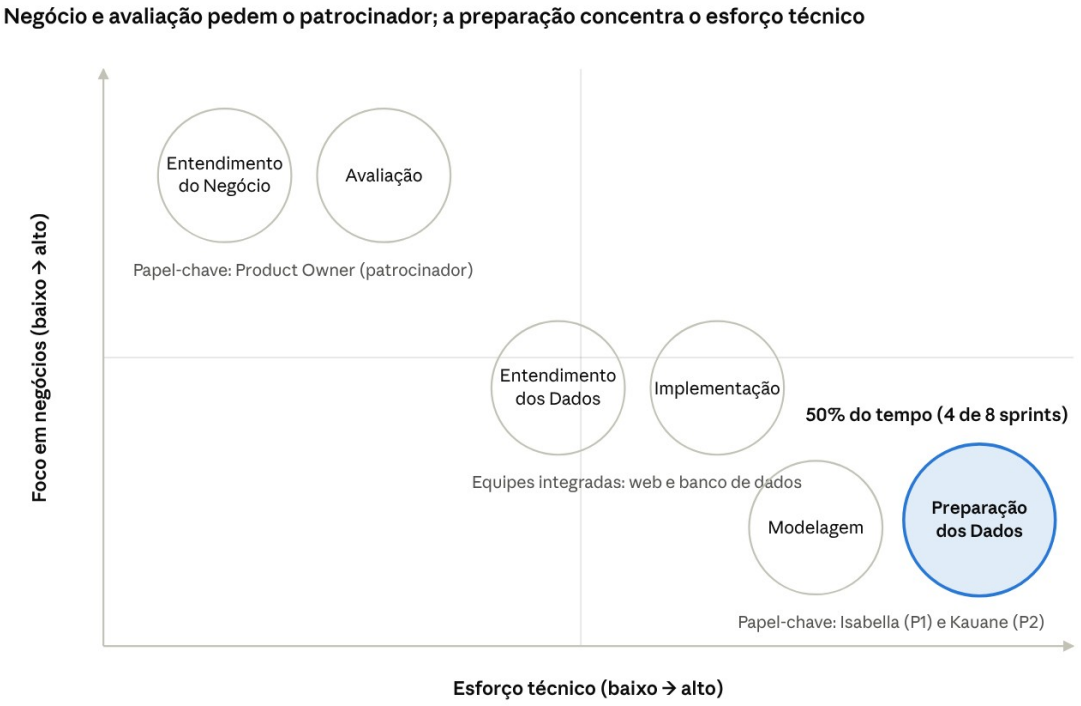
Fluxo CRISP-DM aplicado ao MVC Finance · 6 fases

O fluxo não é linear. No CRISP-DM, recuar não é falhar: cada volta no ciclo melhora o projeto. Os retornos mais prováveis no MVC Finance são:

De → Para	Motivo provável
Dados → Negócio	A base inicial é pequena demais para prever saldo negativo; o escopo encolhe para apenas a recomendação de cursos
Modelagem → Preparação	O K-means exige atributos padronizados e sem valores ausentes, forçando novo tratamento dos meses incompletos
Avaliação → Negócio	O modelo tem bom recall, mas os alertas não mudam o comportamento; a premissa de negócio precisa ser revista

Matriz de realidade do projeto

O sucesso do projeto depende da comunicação entre áreas com focos opostos: as fases de negócio pedem o patrocinador, e as fases técnicas pedem as cientistas de dados.



Matriz de realidade do projeto · 6 fases em dois eixos

No MVC Finance, o Product Owner (o papel de patrocinador definido no Scrum do TCC) conduz o Entendimento do Negócio e a Avaliação. Isabella (P1) e Kauane (P2) concentram a Preparação e a Modelagem. O Entendimento dos Dados e a Implementação exigem as equipes integradas de desenvolvimento web e de banco de dados.

Resumo executivo: checklist para o sucesso

- ☒ **Comece pelo negócio:** as duas perguntas nasceram de uma limitação real do TCC, a integração entre finanças e educação ser apenas de navegação.
- ☒ **Respeite o atrito:** metade do plano (4 de 8 sprints) foi reservada para a preparação dos dados, que corrigiu datas futuras, categorias incoerentes e erros de digitação.
- ☒ **Abrace a iteração:** modelos simples rodaram primeiro (regressão logística e K-means). A avaliação fez o ciclo voltar duas vezes: à regra de limpeza e ao número de clusters.
- ☒ **Meça o impacto:** além das métricas técnicas, os critérios finais são de negócio, como a taxa de início dos cursos recomendados e a queda dos meses negativos, medidas por teste A/B.
- ☒ **Documente a jornada:** o repositório traz o SQL, o PDF das consultas, o notebook e o dashboard, para que as regras possam ser levadas à equipe de TI.

Parte prática (dados simulados)

O notebook em Python que acompanha este trabalho executou as seis fases sobre uma base simulada e atingiu os quatro critérios técnicos, mas revelou que o alerta quase não funciona para o Plano Gratuito.

Como o MVC Finance ainda não tem usuários reais, a base foi gerada com a mesma estrutura do banco (Usuario, Operacao, TipoOperacao, Categoria e MetodoPagamento) e com as regras do sistema, incluindo o limite de 10 operações por mês. São 400 usuários e 60.527 operações de janeiro a dezembro de 2026, com erros inseridos de propósito. **Os números abaixo demonstram o método e não são resultados do sistema em produção.** Ferramentas: Python, pandas e scikit-learn.

A parte prática foi organizada como um repositório (MVCFinance-CRISP-DM-Analysis), no mesmo formato do projeto de referência PizzaHut-Sales-Analysis:

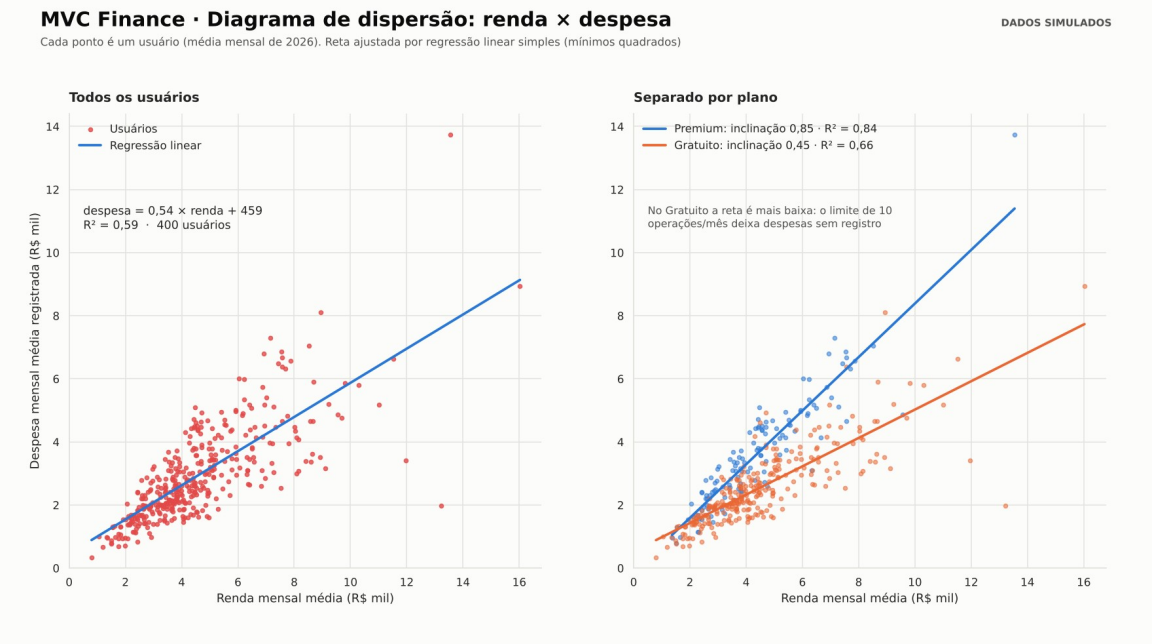
- **Dados:** a base em CSV.
- **SQL:** o arquivo `mvc_finance.sql` (PostgreSQL), com validações de qualidade (V1–V6), uma view com a base limpa, sete KPIs e duas consultas de apoio.
- **Relatório das consultas:** um PDF com cada consulta e o seu resultado.
- **Notebook:** abre no Google Colab.
- **Dashboard:** três páginas. No lugar do Power BI, foi feito em Python com as bibliotecas de visualização da disciplina: Pandas agrega os dados, Seaborn desenha os gráficos e Matplotlib monta as páginas.

Fases 2 e 3 – Qualidade e preparação

A verificação encontrou 25 operações com data futura (removidas), 605 despesas em categoria de depósito (604 reclassificadas) e 226 valores acima de 10 vezes a mediana do próprio usuário na categoria (corrigidos como erro de digitação). A primeira versão dessa regra usava a mediana geral da categoria e corrigia por engano investimentos legítimos de quem investe muito, o que exigiu uma iteração na Fase 3. O e-mail foi trocado por um código hash e a tabela analítica final ficou com 4.549 linhas usuário-mês e 33 colunas.

Diagrama de dispersão e regressão linear

Quanto maior a renda, maior a despesa registrada. Mas a reta do Plano Gratuito é quase metade da do Premium, o que mostra visualmente o efeito do limite de 10 operações.



Cada ponto é um usuário, com a sua renda mensal média (depósitos) no eixo x e a despesa mensal média registrada no eixo y. A reta foi ajustada por regressão linear simples (mínimos quadrados), e o R^2 indica quanto da variação da despesa é explicado pela renda.

Grupo	Usuários	Equação da reta	R^2
Todos	400	despesa = 0,54 × renda + 459	0,59
Plano Premium	122	despesa = 0,85 × renda − 109	0,84
Plano Gratuito	278	despesa = 0,45 × renda + 530	0,66

No Premium, cada R$ 1,00 a mais de renda vem acompanhado de cerca de R$ 0,85 a mais de despesa. No Gratuito são só R$ 0,45, não porque esses usuários gastem menos, mas porque o limite deixa as despesas menores sem registro. O resultado reforça a hipótese H2 e justifica avaliar os dois planos separadamente na Fase 5.

Fase 4 – Resultados da modelagem

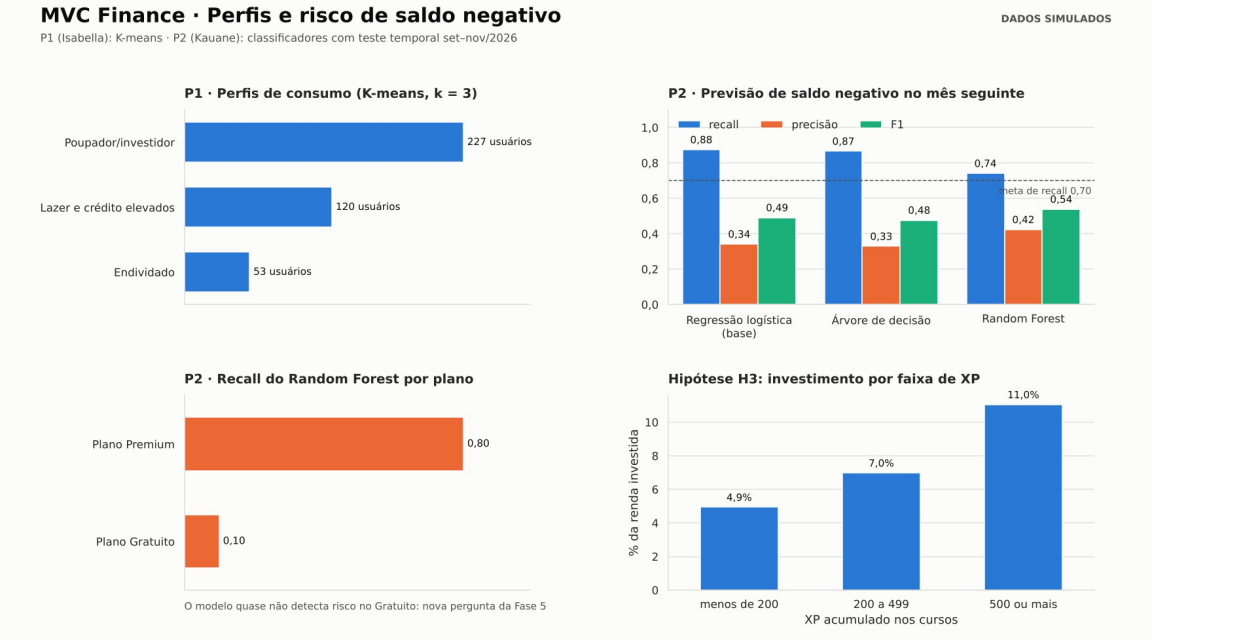
Pergunta 1 (Isabella): o K-means escolheu k = 3 pelo coeficiente de silhueta (0,34):

Perfil encontrado	Usuários	Traço principal	Nível recomendado
Poupador/investidor	227	Investe cerca de 12% da renda	Construção de Patrimônio (cursos 3 e 4)
Lazer e crédito elevados	120	26% dos gastos em lazer e delivery; 65% no cartão de crédito	Fundamentos (cursos 1 e 2)
Endividado	53	23% dos gastos com dívidas e	Fundamentos (cursos 1 e

Perfil encontrado	Usuários	Traço principal	Nível recomendado
		empréstimos	2)

Pergunta 2 (Kauane): na previsão de saldo negativo no mês seguinte, com treino de janeiro a agosto e teste de setembro a novembro:

Modelo	Recall	Precisão	F1	AUC-ROC
Regressão logística (base)	0,88	0,34	0,49	0,90
Árvore de decisão	0,87	0,33	0,48	0,87
Random Forest	0,74	0,42	0,54	0,90



O Random Forest teve o melhor F1 e foi o escolhido. A regressão logística, porém, ficou muito próxima e é mais simples de explicar, o que pode pesar na decisão final.

Fase 5 – Avaliação e iterações

- **Critérios técnicos:** silhueta 0,34 (meta > 0,25); menor cluster com 13% dos usuários (meta ≥ 5%); recall 0,74 (meta ≥ 0,70); F1 0,54 contra 0,49 do modelo base. Todos foram atingidos.
- **Iteração no K-means:** os perfis "essencial" e "poupador" caíram no mesmo cluster. O teste com k = 4 não resolveu, o que indica voltar à Fase 3 e reduzir ou ponderar os atributos.
- **Nova pergunta:** o recall foi de 0,80 no Plano Premium, mas de apenas 0,10 no Gratuito. O KPI 6 do SQL mostra a causa: 99% dos meses do Gratuito chegam ao limite de 10 operações, e só 1,2% deles aparecem com saldo negativo, contra 27,4% no Premium. O limite esconde as despesas menores, confirmando a hipótese H2 na base simulada.

- **Hipótese H3:** usuários com 500 XP ou mais investem 11,0% da renda, contra 4,9% dos que têm menos de 200 XP (consulta de apoio B). É uma correlação que precisa ser testada com usuários reais.

Fase 6 – Protótipo do job mensal

O notebook gera, para cada usuário, o perfil, o curso recomendado (respeitando os cursos liberados por plano, regra RN-P05) e a probabilidade de saldo negativo. Na simulação, 70 dos 400 usuários receberiam alerta em janeiro de 2027. Um monitoramento simples compara a média dos atributos do treino com a dos meses recentes para detectar mudanças de comportamento.

Considerações finais

A aplicação do CRISP-DM mostrou que o MVC Finance já coleta os dados necessários para um projeto de mineração de dados, mas que o maior esforço está na qualidade desses dados: registro manual, ausência de restrição entre tipo e categoria, exclusão permanente e limite do Plano Gratuito. O roteiro em seis fases converte um trabalho futuro do TCC, a recomendação de cursos com base nos gastos, em metas técnicas mensuráveis e em um plano de implementação compatível com a arquitetura atual (Next.js, Prisma e PostgreSQL). Seguindo o checklist do guia, o projeto começa pelo negócio, reserva tempo para a preparação, executa modelos simples cedo, mede impacto real e documenta as regras para a equipe de desenvolvimento.

Respondendo às perguntas de análise, com base nos dados simulados:

- **P1 (Isabella):** sim, há perfis distintos. O K-means encontrou três: Poupador/investidor (227 usuários), Lazer e crédito elevados (120) e Endividado (53), com silhueta de 0,34. Os dois últimos são direcionados aos cursos de Fundamentos e o primeiro aos de Construção de Patrimônio. A limitação é que os perfis "essencial" e "poupador" ainda ficaram juntos.
- **P2 (Kauane):** sim, para o Plano Premium. O Random Forest detectou 74% dos meses negativos (recall 0,74; AUC 0,90), acima da meta de 0,70. No Plano Gratuito o recall cai para 0,10, porque o limite de 10 operações esconde despesas. Para esses usuários, é preciso enriquecer a base antes de usar o alerta.

Referências

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília, DF: Presidência da República, 2018.

CHAPMAN, P. et al. **CRISP-DM 1.0**: step-by-step data mining guide. [S. l.]: SPSS, 2000.

CONFEDERAÇÃO NACIONAL DO COMÉRCIO DE BENS, SERVIÇOS E TURISMO (CNC). **Pesquisa de Endividamento e Inadimplência do Consumidor (PEIC)**. Brasília, DF: CNC, 2024. Disponível em: https://www.portaldocomercio.org.br. Acesso em: 10 abr. 2026.

COMISSÃO DE VALORES MOBILIÁRIOS (CVM). **Educação financeira para além do conhecimento**: barreiras e facilitadores ao comportamento de poupar e investir. Rio de Janeiro: CVM, 2017. Disponível em: https://www.gov.br/cvm/pt-br. Acesso em: 11 abr. 2026.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011.

SOUSA, I. A. D.; SANTOS, J. M.; SOUSA, K. B. S. S. **MVC Finance**: aplicativo web de gestão financeira pessoal. 2026. Trabalho de Conclusão de Curso (Graduação em Sistemas de Informação e em Ciência da Computação) – Centro Universitário do Distrito Federal, Brasília, 2026.

VALÉRIA, K. **Guia definitivo**: o modelo CRISP-DM. Material didático da disciplina Ciência de Dados e Aprendizagem de Máquina. Brasília: UDF, 2026.